基于多方向特征融合的图像分类鲁棒性研究

机器学习课程设计开题报告

1 研究的问题

本课题拟研究图像发生方向变化时，小型卷积神经网络的分类稳定性问题。以自然图像分类为场景，考察同一对象在不同旋转方向下的特征和预测差异，探索在基础分类网络中加入多方向特征融合模块，能否更充分地利用各方向的判别信息，并在可接受的计算开销下改善分类表现。研究范围以可控的离散旋转为主。

2 问题的重要性和意义

图像采集角度与设备摆放方式会影响对象在画面中的方向。当类别语义保持不变时，分类结果仍可能随方向改变而波动。研究这一问题，有助于理解模型对输入变换的敏感性，以及数据增强、参数共享和特征融合各自的作用。课题使用公开小型数据集和经典网络，便于完成从错误分析、模块实现到对照验证的完整过程，适合在课程设计中运用卷积、池化、交叉熵损失和泛化评价等知识。

3 前人工作存在的问题

经典卷积神经网络通过卷积与空间池化提取局部特征[1]，但这些操作本身并不保证旋转前后的分类一致。旋转数据增强可以扩大训练样本的方向覆盖，模型仍需从数据中学习方向变化与类别之间的关系。推理时对多方向预测进行平均是直接有效的对照，但其融合发生在分类输出端，对中间特征的互补信息利用有限。

TI-pooling 等工作提供了跨变换聚合特征的思路[2]。这类机制在课程采用的小型网络和数据设置下是否有效，仍需与充分训练的增强及预测融合对照比较。自然图像的方向有时也包含有用线索，因此还需检查方向融合对原始方向表现的影响，以及收益与额外计算成本的关系。

4 解决方案的关键思路

首先，参考经典卷积网络及 PyTorch 图像分类教程[1,4]建立基础模型，比较原始图像和旋转图像上的表现。通过混淆矩阵、不同方向的预测分歧及典型错误，判断问题主要来自方向敏感、方向间信息利用不足，还是模型容量与训练设置。

其次，拟在卷积特征提取部分与分类头之间新增多方向特征融合模块。对同一图像构造若干方向的视图，采用共享参数的编码器提取特征，再将各方向的响应汇聚为统一表示并完成分类。具体融合形式保留平均、最大响应选择或轻量加权等候选，根据开发集表现、错误类型和实现复杂度确定。训练以类别监督为基础，必要时再探索方向权重学习或预测一致性约束。

课题的改进重点是在已有变换不变特征学习思想基础上，实现适配小型分类网络的模块，并分析其作用条件。实验以一个主要模块为核心，通过去掉模块、替换融合方式等消融，区分结构改动与训练预算、额外参数带来的影响。

5 验证数据集和评价标准

拟采用 CIFAR-10[3]，包含 10 类、32×32 像素的彩色图像。计划将官方训练部分的 50,000 张原图划为训练集、开发集和独立确认集，规模分别为 40,000、5,000 和 5,000 张，先划分原图再生成旋转视图。初步采用 0°、90°、180°和 270°构造方向变化场景，原始方向同时作为检查条件。开发集用于方案与超参数选择，确认集用于方案固定后的评价，官方测试集保留。

对照包括基础 CNN、旋转增强 CNN，以及多方向训练结合简单预测融合的方法。主要比较分类准确率，补充宏平均 F1、每类召回率、方向一致性、参数量和推理耗时。在相近骨干容量、训练预算和视图数量下比较，关键方法计划使用至少 3 个配对随机种子，报告均值、波动和配对收益。统计以原图为单位，避免把同一图像的多个方向当作独立样本。是否保留模块，以其能否稳定超过合理简单对照、改善对应错误并保持可接受开销为依据。

6 组员名单

组号：待填写。组员姓名及学号：待填写。

参考文献与代码

[1] LeCun Y, et al. Gradient-Based Learning Applied to Document Recognition. Proceedings of the IEEE, 1998, 86(11): 2278-2324. 论文页面

[2] Laptev D, et al. TI-pooling: transformation-invariant pooling for feature learning in Convolutional Neural Networks. CVPR, 2016: 289-297. 论文与作者代码

[3] Krizhevsky A. Learning Multiple Layers of Features from Tiny Images. University of Toronto, 2009. 数据与报告

[4] PyTorch Tutorials. Training a Classifier. 官方教程与代码