# 基于多方向特征融合的旋转鲁棒图像分类研究

机器学习课程设计开题报告

## 一、研究问题

本课题拟研究自然图像发生旋转时，小型卷积神经网络的分类稳定性与识别准确率问题。例如，一张卡车图像旋转 90°后仍应属于卡车类别，但车身轮廓和局部纹理的方向发生变化，原来能够响应这些特征的卷积核未必产生相近的响应，分类置信度甚至预测类别也可能改变。对于 32×32 像素的图像，可供识别的细节较少，更需要考察不同方向下哪些线索能够被模型有效利用。

研究将以 0°、90°、180°和 270°的离散旋转为受控场景，重点分析同一图像在不同方向下的预测分歧，以及部分方向预测正确、融合后仍分类错误的情况。在此基础上，考察将多方向信息的融合位置前移到特征层，能否比旋转增强和简单预测融合取得更稳定的分类收益。实验结论限定于上述旋转设置。

## 二、问题的重要性和意义

图像采集角度与设备摆放方式会影响对象在画面中的方向。当类别语义保持不变时，分类结果仍可能随方向改变而波动。研究这一问题，有助于理解模型对输入变换的敏感性，以及数据增强、参数共享和特征融合各自的作用。课题使用公开小型数据集和经典网络，便于完成从错误分析、模块实现到对照验证的完整过程，适合在课程设计中运用卷积、池化、交叉熵损失和泛化评价等知识。

## 三、已有工作的不足

经典卷积神经网络依靠卷积与空间池化提取局部特征[1]，这些结构可以减弱局部位移的影响，但本身不保证旋转前后的表示或预测一致。旋转数据增强能让模型见到更多方向的样本，训练仍主要要求每个视图分别分类正确，没有直接约束不同方向的特征如何共同服务于一次分类。在模型容量和训练预算有限时，其效果还需结合方向间的预测差异判断。

多方向预测平均是一种简单且有竞争力的方法，但融合时各方向的特征已被压缩为类别概率，模型无法在分类头之前组合它们的细节响应。如果某个方向给出了正确类别，而其他方向对错误类别的置信度较高，平均结果仍可能出错。完整平均四个直角方向的预测本身也具有四方向不变性，因此，输出是否一致不足以说明新增模块有效，还需比较分类准确率。

TI-pooling 已采用共享编码与跨变换最大聚合来学习不变特征[2]，为本课题提供了直接参考。需要进一步验证的是，这一思路接入课程的小型 CNN 后，在相同训练预算和视图数量下能否超过简单预测融合。自然图像的方向也可能包含有用线索，融合是否损失这些线索、对哪些类别有帮助，以及额外计算是否值得，都需要具体实验回答。

## 四、解决方案的关键思路

本课题参考经典卷积网络及 PyTorch 图像分类教程[1,4]建立基础模型，比较原始图像和旋转图像上的表现。通过混淆矩阵、不同方向的预测分歧及典型错误，判断问题主要来自方向敏感、方向间信息利用不足，还是模型容量与训练设置。

针对错误分析中发现的问题，拟在卷积特征提取部分与分类头之间新增多方向特征融合模块。对同一图像构造若干方向的视图，采用共享参数的编码器提取特征，再将各方向的响应汇聚为统一表示并完成分类。具体融合形式保留平均、最大响应选择或轻量加权等候选，根据开发集表现、错误类型和实现复杂度确定。训练以类别监督为基础，必要时再探索方向权重学习或预测一致性约束。

课题的改进重点是在已有变换不变特征学习思想基础上，实现适配小型分类网络的模块，并分析其作用条件。实验通过去掉模块、替换融合方式等消融，区分结构改动与训练预算、额外参数带来的影响。

## 五、验证数据集和评价标准

拟采用 CIFAR-10[3]，包含 10 类、32×32 像素的彩色图像。计划将官方训练部分的 50,000 张原图划为训练集、开发集和独立确认集，规模分别为 40,000、5,000 和 5,000 张，先划分原图再生成旋转视图。初步采用 0°、90°、180°和 270°构造方向变化场景，原始方向同时作为检查条件。开发集用于方案与超参数选择，确认集及官方测试集用于方案固定后的评价。

对照包括基础 CNN、旋转增强 CNN，以及多方向训练结合简单预测融合的方法。主要比较分类准确率，补充宏平均 F1、每类召回率、方向一致性、参数量和推理耗时。在相近骨干容量、训练预算和视图数量下比较，关键方法计划使用至少 3 个配对随机种子，报告均值、波动和配对收益。统计以原图为单位，避免把同一图像的多个方向当作独立样本。是否保留模块，以其能否稳定超过合理简单对照、改善对应错误并保持可接受开销为依据。

## 六、组员名单

组号：28。组员姓名：何皓天、王彦哲、陈鑫、张浩稷、陶莎。

## 参考文献与代码

[1] LeCun Y, et al. Gradient-Based Learning Applied to Document Recognition. Proceedings of the IEEE, 1998, 86(11): 2278-2324. 论文页面

[2] Laptev D, et al. TI-pooling: transformation-invariant pooling for feature learning in Convolutional Neural Networks. CVPR, 2016: 289-297. 论文与作者代码

[3] Krizhevsky A. Learning Multiple Layers of Features from Tiny Images. University of Toronto, 2009. 数据与报告

[4] PyTorch Tutorials. Training a Classifier. 官方教程与代码